

概率论与数理统计

核心知识点、公式与解题框架总结

Generated by Codex · Typst Pipeline

首页速览

- 核心公式:** $P(A|B) = \frac{P(AB)}{P(B)}$, $E(X) = \int xf(x)dx$, $D(X) = E(X^2) - E^2(X)$ 。
- 关键定理:** 全概率公式、Bayes 公式、独立性判定、大数定律和中心极限定理构成概率题主线。
- 方法抓手:** 分布题先写清样本空间和区域; 二维随机变量用二重积分算概率; 函数分布用分布函数法或变量变换法。

使用说明

本文面向概率论与数理统计课程复习，重点整理概念、公式、典型题型与易错点。阅读顺序建议为：先掌握事件与随机变量，再理解分布与数字特征，最后进入参数估计、假设检验和回归分析。

核心主线： 概率论研究随机现象本身，回答“随机变量如何分布、期望和方差是多少”；数理统计基于样本推断总体，回答“参数如何估计、假设如何检验、模型是否可靠”。

一、随机事件与概率

事件关系与运算

随机试验的结果集合称为样本空间，记为 Ω ；样本空间的子集称为事件。常见事件运算包括并、交、差和补：

$$A \cup B, A \cap B, A - B, A^c$$

若 $A \cap B = \emptyset$ ，则称 A 与 B 互斥；若 $P(A \cap B) = P(A)P(B)$ ，则称二者相互独立。互斥强调事件不能同时发生，独立强调一个事件的发生不影响另一个事件的概率。

概率公理与常用公式

概率公理： 对任意事件 A ，有 $0 \leq P(A) \leq 1$ ，且 $P(\Omega) = 1$ 。若事件列 $A_1, A_2, \dots$ 两两互斥，则

$$P(\cup_i A_i) = \sum_i P(A_i)$$

常用公式：

$$P(A^c) = 1 - P(A)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A - B) = P(A) - P(A \cap B)$$

对三个事件：

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

条件概率、乘法公式与全概率公式

当 $P(B) > 0$ 时，条件概率定义为：

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

乘法公式：

$$P(A \cap B) = P(B)P(A | B) = P(A)P(B | A)$$

若 $B_1, B_2, \dots, B_n$ 构成样本空间的一个划分，且 $P(B_i) > 0$ ，则：

$$P(A) = \sum_{i=1}^n P(B_i)P(A | B_i)$$

贝叶斯公式：

$$P(B_k | A) = \frac{P(B_k)P(A | B_k)}{\sum_{i=1}^n P(B_i)P(A | B_i)}$$

解题抓手： 已知“原因到结果”的概率时用全概率公式求结果概率；已知结果后反推原因概率时用贝叶斯公式。题目中出现“来自某机器、某盒、某人群、某批次”通常提示划分事件。

二、随机变量与分布函数

随机变量

随机变量是定义在样本空间上的实值函数，用于把随机结果数量化。按取值特点可分为离散型随机变量与连续型随机变量。

离散型随机变量用分布律描述：

$$P(X = x_i) = p_i, \quad p_i \geq 0, \quad \sum_i p_i = 1$$

连续型随机变量用概率密度函数 $f(x)$ 描述：

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x) dx = 1$$

区间概率为：

$$P(a < X \leq b) = \int_a^b f(x) dx$$

分布函数

任意随机变量的分布函数定义为：

$$F(x) = P(X \leq x)$$

性质：

- $F(x)$ 单调不减；
- $0 \leq F(x) \leq 1$ ；
- $\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1$ ；
- $F(x)$ 右连续。

若 X 为连续型随机变量，则 $F'(x) = f(x)$ ，且：

$$F(x) = \int_{-\infty}^x f(t) dt$$

易错点： 离散型随机变量在单点上可以有正概率；连续型随机变量满足 $P(X = a) = 0$ 。因此连续型变量中 $P(a < X < b)$ 、 $P(a \leq X < b)$ 、 $P(a < X \leq b)$ 通常相同。

三、常见离散分布

分布	适用场景	分布律	期望与方差
两点分布	一次试验成败	$P(X = 1) = p, P(X = 0) = 1 - p$	$E(X) = p, \text{Var}(X) = p(1 - p)$
二项分布	n 次独立重复试验成功次数	$P(X = k) = C_n^k p^k (1 - p)^{n-k}$	$E(X) = np, \text{Var}(X) = np(1 - p)$
泊松分布	稀有事件计数	$P(X = k) = \lambda^k \frac{e^{-\lambda}}{k!}$	$E(X) = \lambda, \text{Var}(X) = \lambda$
几何分布	首次成功所需试验次数	$P(X = k) = (1 - p)^{k-1} p$	$E(X) = \frac{1}{p}, \text{Var}(X) = \frac{1-p}{p^2}$

二项分布写作 $X \sim B(n, p)$ ，泊松分布写作 $X \sim P(\lambda)$ 。当 n 很大、 p 很小且 $np = \lambda$ 适中时，二项分布可用泊松分布近似：

$$B(n, p) \approx P(\lambda), \quad \lambda = np$$

判断口诀： 固定次数看成功个数用二项分布；单位时间或区域内的随机次数用泊松分布；问“第一次成功在第几次”用几何分布。

四、常见连续分布

均匀分布

若 $X \sim U(a, b)$, 则:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$E(X) = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

$U(0, 1)$ 密度为 1 的理解: 若 $X \sim U(0, 1)$, 则 $f(x) = 1$ 表示单位长度上的概率强度为 1, 不是说某一点的概率等于 1。对任意 $0 \leq a < b \leq 1$,

$$P(a \leq X \leq b) = \int_a^b 1dx = b - a$$

所以区间概率等于区间长度; 单点概率仍为 $P(X = c) = \int_c^c 1dx = 0$ 。

密度不等于概率: 概率密度可以等于 1, 也可以大于 1, 但概率不能大于 1。密度必须在区间、区域或体积上积分, 才得到概率。

概率为 0 的事件和不可能事件

在连续型随机变量中, 概率为 0 的事件仍然可能发生; “概率为 0”不等于“不可能”。真正的不可能事件, 是样本空间中根本没有对应结果的事件。

设

$$X \sim U(0, 1)$$

则对任意固定点 $c \in [0, 1]$, 有:

$$P(X = c) = \int_c^c 1dx = 0$$

但是一次试验发生后, X 总会取到 $[0, 1]$ 中某一个具体值。也就是说, 每一个事先指定的单点概率都是 0, 但最终结果仍然落在某一个点上。

若 $X \sim U(0, 1)$, 则:

事件	概率	是否可能
$X = 0.5$	0	可能; 但概率为 0
$X = 2$	0	不可能; 不在取值范围内
$0.2 \leq X \leq 0.5$	0.3	可能; 区间长度为 0.3

概率为 1 的事件也不一定是逻辑必然, 而是“几乎必然”。例如若 $X \sim U(0, 1)$, 则

$$P(X \text{ 是无理数}) = 1$$

因为有理数是可数集合，在连续均匀分布下总概率为 0。但这不表示 X 取到有理数在逻辑上绝对不可能，只表示其概率为 0。

一句话总结： 概率为 0 表示这个事件在概率尺度下“没有长度、没有面积或没有体积”，不等于集合上不存在；连续型分布中，单点事件通常概率为 0，但它仍可能作为一次试验的具体结果出现。

指数分布

若 $X \sim \text{Exp}(\lambda)$ ，通常用于描述等待时间：

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

$$E(X) = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

指数分布具有无记忆性：

$$P(X > s + t \mid X > s) = P(X > t)$$

正态分布

若 $X \sim N(\mu, \sigma^2)$ ，其密度为：

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

标准化：

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

概率计算通常转化为标准正态分布函数 $\Phi(x)$ ：

$$P(a < X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

正态分布经验法则： 约 68% 的数据落在 $\mu \pm \sigma$ 内，约 95% 落在 $\mu \pm 2\sigma$ 内，约 99.7% 落在 $\mu \pm 3\sigma$ 内。

高斯积分与正态密度归一化

标准正态密度中的系数 $\frac{1}{\sqrt{2\pi}}$ 来自高斯积分：

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$$

令

$$I = \int_{-\infty}^{+\infty} e^{-x^2} dx$$

因为 $e^{-x^2} > 0$ ，所以 $I > 0$ 。两边平方：

$$I^2 = \iint_{\mathbb{R}^2} e^{-(x^2+y^2)} dx dy$$

改用极坐标 $x = r \cos \theta, y = r \sin \theta$, 有 $dx dy = r dr d\theta$, 整个平面对应

$$0 \leq r < +\infty, \quad 0 \leq \theta \leq 2\pi$$

于是

$$I^2 = \int_0^{2\pi} \int_0^{+\infty} e^{-r^2} r dr d\theta$$

令 $u = r^2$, 则 $r dr = \frac{1}{2} du$, 所以

$$\int_0^{+\infty} e^{-r^2} r dr = \frac{1}{2} \int_0^{+\infty} e^{-u} du = \frac{1}{2}$$

因此

$$I^2 = \int_0^{2\pi} \frac{1}{2} d\theta = \pi$$

由于 $I > 0$, 得到

$$I = \sqrt{\pi}$$

进一步把 $t = \frac{x}{\sqrt{2}}$ 可得

$$\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$$

所以标准正态密度

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

的全实轴积分正好为 1。

五、多维随机变量

联合分布与边缘分布

二维离散型随机变量通过联合分布律 $P(X = x_i, Y = y_j) = p_{ij}$ 描述；边缘分布通过求和得到：

$$P(X = x_i) = \sum_j p_{ij}, \quad P(Y = y_j) = \sum_i p_{ij}$$

二维连续型随机变量通过联合密度 $f(x, y)$ 描述：

$$P((X, Y) \in D) = \int \int_D f(x, y) dx dy$$

二重积分视角： 可以把二维连续型随机变量理解成把概率铺在平面上。联合密度 $f(x, y)$ 是概率密度曲面，事件区域 D 上方的“体积”

$$\int \int_D f(x, y) dx dy$$

就是事件概率。

联合分布函数定义为：

$$F(x, y) = P(X \leq x, Y \leq y)$$

若存在联合密度，则：

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du$$

在可偏导且条件满足时：

$$f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$$

边缘密度：

$$f_{X(x)} = \int_{-\infty}^{\infty} f(x, y) dy$$

$$f_{Y(y)} = \int_{-\infty}^{\infty} f(x, y) dx$$

独立性

若对所有 x, y ，有：

$$F(x, y) = F_{X(x)} F_{Y(y)}$$

则 X 与 Y 相互独立。对连续型变量，常用密度判断：

$$f(x, y) = f_{X(x)} f_{Y(y)}$$

判断提醒：联合密度能分解成两个单变量函数只是必要线索，还要注意定义域是否也能分解为两个单变量区间的笛卡尔积。

组合随机变量的密度

设二维随机变量为 (X, Y) ，联合密度为 $f_{X,Y}(x, y)$ ，新随机变量

$$Z = g(X, Y)$$

求 Z 的密度时，最通用的方法是分布函数法。先求

$$F_{Z(z)} = P(Z \leq z) = P(g(X, Y) \leq z)$$

把事件 $g(X, Y) \leq z$ 翻译成平面区域 D_z ，则

$$F_{Z(z)} = \int \int_{D_z} f_{X,Y}(x, y) dx dy$$

最后对 z 求导：

$$f_{Z(z)} = F'_{Z(z)}(z)$$

常见组合公式如下。

若 $Z = X + Y$ ，则：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X,Y}(x, z-x) dx$$

若 X, Y 独立，则卷积公式为：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X(x)} f_{Y(z-x)} dx$$

若 $Z = X - Y$ ，则：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X,Y}(x, x-z) dx$$

若 X, Y 独立，则：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X(x)} f_{Y(x-z)} dx$$

若 $Z = XY$ ，则：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X,Y}\left(x, \frac{z}{x}\right) \frac{1}{|x|} dx \quad (x \neq 0)$$

若 $Z = \frac{X}{Y}$ ，则：

$$f_{Z(z)} = \int_{-\infty}^{+\infty} f_{X,Y}(zy, y) |y| dy \quad (y \neq 0)$$

取值范围检查：不要只背公式而忽略定义域。组合变量密度公式中的积分上下限，要和原联合密度的非零区域联立，否则容易把不可能的点也积分进去。

六、数字特征

期望

离散型：

$$E(X) = \sum_i x_i p_i$$

连续型：

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

函数的期望：

$$E(g(X)) = \sum_i g(x_i) p_i$$

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) f(x) dx$$

线性性质：

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

方差、协方差与相关系数

方差：

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - [E(X)]^2$$

常数变换：

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

协方差：

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

相关系数：

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}$$

若 X, Y 独立, 则 $E(XY) = E(X)E(Y)$, 且 $\text{Cov}(X, Y) = 0$ 。反过来, 协方差为 0 一般不一定推出独立, 正态分布等特殊情形除外。

计算优先级： 求方差时优先使用 $\text{Var}(X) = E(X^2) - [E(X)]^2$ ；求线性组合方差时注意协方差项：

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

七、大数定律与中心极限定理

大数定律

大数定律说明样本均值会稳定到总体期望附近。若 $X_1, X_2, \dots, X_n$ 独立同分布, 且 $E(X_i) = \mu$, 则样本均值:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

在概率意义下趋近于 μ :

$$\bar{X} \rightarrow \mu$$

中心极限定理

若 $X_1, X_2, \dots, X_n$ 独立同分布, $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$, 则当 n 较大时:

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \approx N(0, 1)$$

或:

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \approx N(0, 1)$$

核心意义: 即使总体分布不是正态分布, 只要样本量足够大, 样本均值的分布通常可近似为正态分布。这是置信区间和大样本检验的基础。

极限定理的计算口径

大数定律说明“样本平均数会稳定到总体均值”。若

$$A_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

则对任意 $\varepsilon > 0$,

$$P(|A_n - \mu| \geq \varepsilon) \rightarrow 0 \quad (n \rightarrow \infty)$$

若进一步有 $\text{Var}(X_i) = \sigma^2 < +\infty$, 则

$$E(A_n) = \mu, \quad \text{Var}(A_n) = \frac{\sigma^2}{n}$$

由切比雪夫不等式:

$$P(|A_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$$

中心极限定理说明“样本和或样本平均数的随机波动, 标准化以后近似服从正态分布”。记 $S_n = X_1 + \dots + X_n$, 则

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} \approx N(0, 1)$$

若 X_i 是伯努利变量, $P(X_i = 1) = p$, 则 S_n 表示 n 次试验中的成功次数:

$$\frac{S_n - np}{\sqrt{np(1-p)}} \approx N(0, 1)$$

因此可用标准正态分布近似二项分布:

$$P(a \leq S_n \leq b) \approx \Phi\left(\frac{b - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1-p)}}\right)$$

更精细时可作连续性校正:

$$P(a \leq S_n \leq b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{np(1-p)}}\right)$$

对比项	大数定律	中心极限定理
研究对象	样本平均数是否稳定	样本和或样本平均数的波动分布
核心结论	A_n 靠近 μ 的概率趋于 1	标准化后近似 $N(0, 1)$
关键词	稳定、收敛、频率趋于概率	近似正态、标准化、区间概率
常见用途	说明估计量稳定	近似计算大样本概率

概念区分：大数定律不说样本平均数必然等于总体均值，而是说概率意义下趋近。中心极限定理也不是说原随机变量服从正态分布，而是说样本和或样本均值标准化后近似正态。

八、数理统计基础

总体、样本与统计量

总体是研究对象的全体，样本是从总体中抽取的观测值。若 $X_1, X_2, \dots, X_n$ 独立同分布且与总体分布相同，则称为简单随机样本。

不含未知参数的样本函数称为统计量，例如样本均值、样本方差：

$$\begin{aligned} \bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i \\ S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \end{aligned}$$

其中分母取 $n - 1$ 是为了让 S^2 成为总体方差 σ^2 的无偏估计。

三大抽样分布

分布	构造	典型用途
χ^2 分布	若 $Z_i \sim N(0, 1)$ 独立，则 $\sum Z_i^2 \sim \chi^2(n)$	总体方差区间估计与检验
t 分布	$T = \frac{Z}{\sqrt{\frac{Y}{n}}}$ ，其中 $Z \sim N(0, 1)$ ， $Y \sim \chi^2(n)$ 独立	总体方差未知时的均值推断
F 分布	$F = \frac{\frac{Y_1}{n_1}}{\frac{Y_2}{n_2}}$ ，其中 Y_1, Y_2 为独立卡方变量	两个方差比较与方差分析

九、参数估计

点估计

点估计是用样本统计量估计总体未知参数。常见方法包括矩估计法和极大似然估计法。

矩估计法：用样本矩替换总体矩。例如：

$$|(X) \approx E(X)$$

极大似然估计法：选择使样本出现概率最大的参数。若样本联合密度或分布律为 $L(\theta)$ ，则：

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

实际计算常取对数似然：

$$l(\theta) = \ln L(\theta)$$

然后求导令零：

$$\frac{dl(\theta)}{d\theta} = 0$$

估计量评价标准

- 无偏性： $E(\hat{\theta}) = \theta$ ；
- 有效性：在无偏估计中方差更小者更有效；
- 一致性：样本量增大时估计量趋近真实参数。

区间估计

置信区间的一般形式为：

$$\text{估计值} \pm \text{临界值} \times \text{标准误}$$

正态总体、方差已知时，均值 μ 的置信区间为：

$$|(X) \pm z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

正态总体、方差未知时：

$$|(X) \pm t_{\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}$$

总体比例 p 的大样本置信区间：

$$\hat{p} \pm z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

易错点： 置信度 $1 - \alpha$ 描述区间构造方法的长期覆盖率，不应解释成“某个已经算出的固定区间含有参数的概率为 $1 - \alpha$ ”。

十、假设检验

基本思想

假设检验先提出原假设 H_0 和备择假设 H_1 ，再构造检验统计量，并根据显著性水平 α 判断是否拒绝 H_0 。

常见错误：

- 第一类错误： H_0 为真却拒绝，概率为 α ；
- 第二类错误： H_0 为假却未拒绝，概率为 β ；
- 检验功效： $1 - \beta$ 。

均值检验

正态总体、方差已知：

$$Z = \frac{(\bar{X}) - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

正态总体、方差未知：

$$T = \frac{(\bar{X}) - \mu_0}{\frac{S}{\sqrt{n}}} \sim t(n-1)$$

大样本下，即使总体非正态，也常用中心极限定理进行近似 Z 检验。

方差检验

正态总体中检验方差 $\sigma^2 = \sigma_0^2$ ：

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

两个正态总体方差比较：

$$F = \frac{S_1^2}{S_2^2}$$

通常令较大样本方差放在分子，便于单侧查表或计算。

P 值

P 值是在原假设成立时，得到当前样本结果及更极端结果的概率。若 $P \leq \alpha$ ，则拒绝 H_0 ；若 $P > \alpha$ ，则不能拒绝 H_0 。

检验步骤模板： 写出 H_0, H_1 ；确定显著性水平 α ；选择统计量并说明分布；计算统计量或 P 值；作出拒绝或不拒绝结论；用题目语言解释结果。

十一、方差分析与回归

方差分析

方差分析用于比较多个总体均值是否相等。核心思想是把总变差分解为组间变差和组内变差：

$$SST = SSA + SSE$$

检验统计量：

$$F = \frac{\frac{SSA}{k-1}}{\frac{SSE}{n-k}}$$

若 F 足够大，说明组间差异相对于组内波动显著，倾向于拒绝“各组均值相等”的原假设。

一元线性回归

一元线性回归模型：

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

其中 ε 为随机误差，通常假设 $E(\varepsilon) = 0$ ，方差恒定，且不同观测之间相互独立。

最小二乘法选择使残差平方和最小的参数：

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

斜率估计：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

截距估计：

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

决定系数：

$$R^2 = 1 - \frac{SSE}{SST}$$

R^2 表示模型解释的因变量总变差比例，但 R^2 高不一定说明因果关系成立。

十二、常见题型处理策略

概率计算题

- 先定义事件，避免直接套公式导致事件含义混乱；
- 判断是否互斥、独立或条件概率；
- 多原因导致同一结果时优先考虑全概率公式；
- 结果反推原因时使用贝叶斯公式；
- 至少检查最终概率是否落在 $[0, 1]$ 。

分布题

- 明确随机变量的取值范围；
- 离散型写出所有可能取值及概率；
- 连续型先确定密度常数，再积分求概率；
- 求分布函数时分区间讨论；
- 求函数分布时注意单调变换、反函数和取值范围。

统计推断题

- 明确总体分布、样本量、方差是否已知；
- 均值推断中方差已知用 Z ，方差未知且正态总体用 t ；
- 方差推断通常要求总体正态；
- 大样本比例推断使用正态近似；
- 写结论时必须回到题目背景。

总易错清单： 把互斥误认为独立；连续型随机变量在单点上赋正概率；忘记密度函数定义域；方差计算漏掉平方系数；把“不拒绝 H_0 ”写成“证明 H_0 正确”；置信区间和假设检验中的 $\frac{\alpha}{2}$ 使用错误。

十三、公式速查

主题	核心公式
条件概率	$P(A B) = \frac{P(A \cap B)}{P(B)}$
全概率公式	$P(A) = \sum_i P(B_i)P(A B_i)$
贝叶斯公式	$P(B_k A) = P(B_k) \frac{P(A B_k)}{\sum_i P(A B_i)} P(A B_i)$
期望	$E(X) = \sum x_i p_i$ 或 $E(X) = \int x f(x) dx$
方差	$\text{Var}(X) = E(X^2) - [E(X)]^2$
协方差	$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$
样本均值	$\bar{X} = \frac{1}{n} \sum_i X_i$
样本方差	$S^2 = \frac{1}{n-1} \sum_i (X_i - \bar{X})^2$
均值置信区间	$\bar{X} \pm \text{临界值} \times \text{标准误}$
线性回归	$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

十四、复习建议

概率论部分建议围绕“事件-随机变量-分布-数字特征-极限定理”建立知识链。数理统计部分建议围绕“样本-统计量-估计-检验-模型”建立推断链。做题时不要先背公式，而要先判断问题类型、变量类型、分布条件和是否满足近似条件。

最终框架：概率论负责建模，统计负责推断；分布是桥梁，样本是证据，期望和方差是最常用的摘要，置信区间和假设检验是最核心的推断工具。